Notas de Processos Estocásticos e Aplicações

Licenciatura em Matemática Aplicada à Economia e Gestão

Nuno M. Brites

2025-07-23

Conteúdo

5

1 Introdução aos processos estocásticos **7**
1.1 Introdução . . . 7
1.2 Tipos clássicos de processos estocásticos . . . 8
1.2.1 Processos de incrementos independentes e estacionários . . . 8
1.2.2 Processo estocástico real de 2ª ordem . . . 9
1.2.3 Processos estacionários . . . 9
1.2.4 Martingalas . . . 12
1.2.5 Processos de Markov . . . 13

2 Cadeias de Markov em tempo discreto **15**
2.1 Introdução . . . 15
2.1.1 Conceitos básicos . . . 15
2.2 Classificação de estados de uma C.M. . . . 18
2.2.1 Decomposição do espaço de estados . . . 24
2.3 Probabilidades de absorção em estados recorrentes . . . 26
2.4 Teoremas limite . . . 29
2.4.1 Distribuição estacionária e distribuição limite . . . 29
2.4.2 Comportamento limite de P_{ij}^n quando $n \to +\infty$ . . . 30

3 Cadeias de Markov em tempo contínuo **33**

Bibliografia **35**

Todas as informações relacionadas com esta UC encontram-se no Fénix.

Todos os erros e omissões são da minha inteira responsabilidade. Caso detete algum erro ou gralha, muito agradeço que me informe. Sugestões e comentários também serão muito bem-vindos!

Esta sebenta não substitui o livro principal.

Obrigado,

Nuno M. Brites

nbrites@iseg.ulisboa.pt

ISEG, Setembro de 2025

Todos os direitos reservados. Nenhuma parte do conteúdo deste sítio pode ser reproduzida ou distribuída sem a autorização prévia por escrito do autor. Sem autorização prévia por escrito, não é permitido copiar ou reproduzir o texto, código e imagens.

2025 | Nuno M. Brites | nbrites@iseg.ulisboa.pt

Capítulo 1

Introdução aos processos estocásticos

1.1 Introdução

Quando se pretende estudar fenómenos que não têm qualquer evolução, usam-se **amostras aleatórias** (repetições de observações i.i.d.'s). Mas, e se estivermos perante **variáveis aleatórias** que já se observaram (ou podiam observar) no passado e que poderemos observar no futuro? Tal ocorre quando pretendemos estudar, por exemplo:

- cotação diária de uma ação na bolsa de valores;
- evolução da taxa de desemprego num dado período;
- número de pessoas que chegam a uma certa fila para serem atendidas;
- evolução da temperatura num local;
- ...

Nos casos acima descritos dispomos apenas de uma única observação (chamada **trajetória**) a partir da qual se pretende extrair conclusões. Nesta trajetória não existe independência entre observações. Tipicamente pretendemos fazer:

- previsão de observações futuras;
- identificação do tipo de evolução;
- filtragem (previsão com a ajuda de observações parciais).

Definição 1.1 (Processo estocástico)**.** Um **processo estocástico** (PE) é uma família de v.a $\{X_t,\ t \in T\}$, definida sobre o mesmo espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e assumindo valores num mesmo espaço mensurável $(E, \mathcal{B})$, onde:

- T : espaço dos parâmetros (ou do tempo);
- Ω : espaço de resultados possíveis;
- $\mathcal{F}$: família de acontecimentos;
- P : medida de probabilidade;
- E : conjunto (a definir posteriormente);
- $\mathcal{B}$: $\sigma-$álgebra de Borel definida em E.

Nota . A $\sigma-$álgebra de Borel definida em E satisfaz:

- $E \in \mathcal{B}$ e $\emptyset \in \mathcal{B}$;
- $\mathcal{B}$ é fechado relativamente à diferença, isto é, $\forall A \in \mathcal{B} : A^c \in \mathcal{B}$;
- $\mathcal{B}$ é fechado relativamente à reunião numerável, isto é, $\bigcup_{i=1}^{n} A_i \in \mathcal{B},\ A_i \in \mathcal{B},\ i = 1, \dots, n.$

Nota .

- Dado um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e um conjunto arbitrário T, um PE é uma função $X(t, \omega)$ definida em $T \times \Omega$, tal que, para cada $t \in T$, $X_t(\omega)$ é uma v.a..

- O conceito de PE generaliza o de v.a. fazendo-a depender de um parâmetros t com domínio em T. Assim, podemos interpretar um PE como uma família ordenada de v.a.'s.
- Para cada ω_0 fixo, $\omega_0 \in \Omega$, $X(\omega_0, t)$ é uma função não aleatória de t. Deste modo, um PE pode identificar-se com um sistema que a cada ponto $\omega \in \Omega$, faz corresponder uma função de parâmetro t. Cada uma dessas funções diz-se uma trajetória ou realização do processo X.

Definição 1.2 (Trajetória de um processo estocástico)**.** Chama-se **trajetória** ou **realização** de um processo estocástico X à coleção $\{X_t(\omega), t \in T\}$, $\forall\ \omega \in \Omega$.

Nota . Em geral $(E, \mathcal{B}) = (\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n})$, onde:

- $\mathbb{R}^n$: conjunto dos possíveis valores do processo X_t;
- $\mathcal{B}_{\mathbb{R}^n}$: $\sigma-$álgebra dos borelianos de $\mathbb{R}^n$;
- Se $n = 1$ o PE chama-se processo estocástico univariado;
- Se $n > 1$ o PE chama-se processo estocástico multivariado;
- t : instante onde é feita a observação ou o período relativo a essa observação;
- Se E for finito ou infinito numerável então X é um PE de espaço de estados discreto;
- Se $E = \mathbb{R}$ então X é um PE de valores reais;
- Se T for finito ou infinito numerável então X é um PE de tempo discreto (tipicamente $T = \mathbb{N}_0$ ou $T = \mathbb{Z}$);
- Se T for infinito não numerável então X é um PE de tempo contínuo (tipicamente $T = \mathbb{R}_0^+$ ou $T = \mathbb{R}$).

Exercício 1.1. Para cada um dos seguintes processos estocásticos indique o espaço parâmetro e o espaço de estados:

(a) Sejam X_i a quantidade de cerveja pedida pelo $i-$ésimo cliente que entrou num bar e $N(t)$ o número de clientes que chegaram ao bar até ao instante t. O processo estocástico é

$$Z_t = \sum_{i=1}^{N(t)} X_i,\ t \geq 0,$$

onde Z_t representa a quantidade de cerveja pedida até ao instante t.

(b) Trinta e seis pontos são escolhidos aleatoriamente no Alaska de acordo com alguma distribuição de probabilidade. Centrado em cada um desses pontos é desenhado um círculo de raio aleatório originando assim uma região Δ do Alaska. Seja $X(A)$ o preço do petróleo extraído no solo da região $A \cap \Delta$. O processo é

$$(X(B) :\ B \subset Alaska).$$

(c) Um bebé dorme numa de três posições: (i) de barriga para cima com feição radiante; (ii) enrolada na posição fetal; (iii) na posição fetal, chupando o dedo polegar. Seja X_t a posição de dormir do bebé no instante t. O processo é $(X_t :\ t \geq 0)$.

(d) Seja X_n o estado (ligado ou desligado) de uma fotocopiadora de um escritório ao meio-dia do $n-$ésimo dia. O processo é $(X_n :\ n = 1, 2, \ldots)$.

1.2 Tipos clássicos de processos estocásticos

1.2.1 Processos de incrementos independentes e estacionários

Definição 1.3 (Processo com incrementos inpedendentes)**.** $\{X_t, t \in T\}$ é um PE com **incrementos independentes** sse

$$\forall\ n \in \mathbb{N}, \forall\ t_1, \ldots, t_n \in T :\ t_1 < t_2 < \ldots < t_n \implies X_{t_2} - X_{t_1}, X_{t_3} - X_{t_2}, \ldots, X_{t_n} - X_{t_{n-1}}$$

são v.a.'s mutuamente independentes.

Definição 1.4 (Processo com incrementos estacionários)**.** $\{X_t, t \in T\}$ tem **incrementos estacionários** sse $\forall\ s, t \in T,\ s < t$, a distribuição de $X_t - X_s$ depende apenas da amplitude $t - s$.

Do ponto de vista da modelação, a propriedade de independência de incrementos pode ser postulada para o modelo quando os resultados obtidos em intervalo de tempo disjuntos forem independentes. Adicionalmente, a propriedade de estacionariedade de incrementos pode ser postulada para o modelo quando for plausível que a distribuição de resultados em qualquer intervalo de tempo depende apenas da amplitude desse intervalo.

Definição 1.5 (Processo de incrementos independentes e estacionários)**.** Dado um PE $X := \{X_t, t \in T\}$, onde T está munido de uma relação de ordem, X é um PE de **incrementos independentes e estacionários** sse tiver incrementos independentes e incrementos estacionários.

Nota . Num PE com incrementos estacionários, a distribuição de $X_{t_{1+h}} - X_{t_1}$ é a mesma de $X_{t_{2+h}} - X_{t_2}$, $\forall\ t_1, t_2 \in T$ e $\forall\ h \in \mathbb{N}$.

1.2.2 Processo estocástico real de 2ª ordem

Definição 1.6 (Processo estocástico real de 2ª ordem)**.** $\{X_t, t \in T\}$ é um **PE real de 2ª ordem** sse:

$$\forall\ t \in T : E(X_t^2) < +\infty.$$

Usualmente, a caracterização de um PE de 2ª ordem é feita em termos dos dois primeiros momentos:

- valor médio do processo: $m(t) = E(X_t),\ \forall\ t \in T$;
- covariância do processo: $\Gamma(s,t) = Cov(X_s, X_t),\ \forall\ s,t \in T$.

1.2.2.1 Exemplos de PEs de 2ª ordem

Exemplo 1.1 (Ruído Branco)**.** Chama-se **Ruído Branco** a um PE $\{\varepsilon_t,\ t \in T\}$ que satisfaz:

- $\forall\ t \in T,\ E(\varepsilon_t) = 0$;
- $\forall\ t \in T,\ Var(\varepsilon_t) = \sigma^2$;
- $\forall\ s,t \in T, s \neq t,\ Cov(\varepsilon_s, \varepsilon_t) = 0$.

Exemplo 1.2 (Processo Gaussiano)**.** $\{X_t, t \in T\}$ diz-se um **Processo Gaussiano** sse:

$$\forall\ n \in \mathbb{N}, \forall\ t_1, t_2, \dots, t_n \in T : (X_{t_1}, X_{t_2}, \dots, X_{t_n})$$

for um vetor aleatório Gaussiano, isto é,

$$X_{t_i} \sim \mathcal{N}(\mu, \sigma^2),\ \forall\ t_i \in T.$$

1.2.3 Processos estacionários

Definição 1.7 (Processo estacionário em sentido forte)**.** Um PE $\{X_t, t \in T\}$ é **estacionário em sentido forte** (ou fortemente estacionário) se,

$$\forall\ h \in T, \forall\ n \in \mathbb{N}, \forall\ t_1, \dots, t_n,\ (t_1 < \dots < t_n),\ (X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_n+h}),$$

isto é, se a distribuição de $\{X_t, t \in T\}$ é igual à distribuição de $(X_{t_1+h}, \dots, X_{t_n+h}),\ \forall\ h \in T$.

Como consequência da estacionariedade forte, temos o seguinte Teorema:

Teorema 1.1. *Se $\{X_t, t \in T\}$ é um PE de 2ª ordem e se é fortemente estacionário, então:*

- $E(X_t) = m$, *isto é, a média do processo é independente de t;*
- $\forall\ h \in T,\ \Gamma(t, t+h) = Cov(X_t, X_{t+h}) = Cov(X_0, X_h) = \gamma(h)$, *independente de t.*

Definição 1.8 (Processo estacionário em sentido fraco)**.** Um PE $\{X_t, t \in T\}$ é **estacionário em sentido fraco** (ou estacionário de 2ª ordem), sse:

- $\forall\ t \in T,\ E(X_t^2) < +\infty$;

- $\forall\ t \in T,\ E(X_t) = m$, independente de t;
- $\forall\ t \in T, \forall\ h \in T,\ Cov(X_t, X_{t+h}) = \gamma(h)$, isto é, a covariância apenas depende de h.

Nota . A função $\gamma(h),\ \forall\ h \in T$, chama-se **função de autocovariância**. Se $h = 0$, então $Cov(X_t, X_{t+h}) = Var(X_t) = \gamma(0),\ \forall\ t \in T$. A esta propriedade chama-se propriedade da homocedasticidade.

Vejamos agora que o Ruído Branco, $\{\varepsilon_t,\ t \in T\}$, é um exemplo de um PE estacionário de 2ª ordem:

Exemplo 1.3.

- $E(\varepsilon_t) = 0$;
- $Var(\varepsilon_t) = \sigma^2 \implies E(\varepsilon_t^2) < +\infty$;
- $t \neq s,\ Cov(\varepsilon_s, \varepsilon_t) = 0, \implies$ independência de t e de s.

Assim,

$$\gamma(h) = \begin{cases} \sigma^2, & h = 0, \\ 0, & h \neq 0. \end{cases}$$

Logo, estão satisfeitas as condições de estacionariedade fraca.

Nota (Observação importante).

$$\text{Estacionariedade forte} + E(X_t^2) < +\infty \Rightarrow \text{Estacionariedade fraca.}$$

$$\text{Estacionariedade fraca} \not\Rightarrow \text{Estacionariedade forte.}$$

Exemplo 1.4. Considere o PE $(X_t,\ t \in \mathbb{N})$ onde X_t tem distribuição de Cauchy, isto é, com f.d.p. $f(x) = \dfrac{1}{\pi(1+x^2)}$. Uma vez que não existe $E(X_t)$, então $E(X_t^2)$ não está definido. Assim, o processo é fortemente estacionário mas não é fracamente estacionário.

Propriedade 1.1 (Propriedades da função de autocovariância em processos estacionários)**.** *A função de autocovariância $\gamma(h)$ goza das seguintes propriedades:*

- $\gamma(h) = \gamma(-h), \forall\ h \in \mathbb{Z}$, *isto é, a função de autocovariância é par;*
- $\forall\ n \in \mathbb{N}, \forall\ a_j \in \mathbb{R}, \forall\ t_j \in \mathbb{Z},\ j = 1, \dots, n$:

$$\sum_{j=1}^{n} \sum_{k=1}^{n} a_j a_k \gamma(t_j - t_k) \geq 0,$$

  isto é, trata-se de uma função semi-definida positiva.

Definição 1.9 (Função de autocorrelação em processos estacionários)**.** Seja $\{X_t, t \in T\}$ um PE estacionário. Chama-se **função de autocorrelação** à função ρ definida por:

$$\rho(h) = Corr(X_t, X_{t+h}) = \frac{Cov(X_t, X_{t+h})}{\sqrt{V(X_t)}\sqrt{V(X_{t+h})}} = \frac{\gamma(h)}{\gamma(0)}.$$

Propriedade 1.2 (Propriedades da função de autocorrelação em processos estacionários)**.** *A função de autocorrelação $\rho(h)$ goza das seguintes propriedades:*

- $\rho(h) = \rho(-h), \forall\ h \in \mathbb{Z}$, *isto é, a função de autocovariância é par;*

- $\forall\ n \in \mathbb{N}, \forall\ a_j \in \mathbb{R}, \forall\ t_j \in \mathbb{Z},\ j = 1, \dots, n$:

$$\sum_{j=1}^{n} \sum_{k=1}^{n} a_j a_k \rho(t_j - t_k) \geq 0,$$

isto é, trata-se de uma função semi-definida positiva.

Exercício 1.2. Sejam X e Y duas variáveis aleatórias não enviesadas, não correlacionadas e com a mesma variância $\sigma^2 > 0$. Considere-se o processo estaocástico $(Z_t :\ t \in \mathbb{Z})$ definido por:

$$Z_t = f(t) \cdot X + g(t) \cdot Y, \quad t \in \mathbb{Z},$$

onde f e g são função deterministas.

(a) Encontre expressões para f e g de modo a garantir que o processo $(Z_t :\ t \in \mathbb{Z})$ admita variância constante mas não seja necessariamente estacionário em sentido fraco.

(b) Concretize f e g de modo a que $(Z_t :\ t \in \mathbb{Z})$ seja fracamente estacionário.

Exercício 1.3. Seja $\varepsilon = (\varepsilon_t :\ t \in \mathbb{Z})$ um ruído branco de variância $\sigma^2 > 0$. Considere os processos estocásticos $X = (X_t :\ t \in \mathbb{Z})$ e $Y = (Y_t :\ t \in \mathbb{Z})$ definidos do seguinte modo:

$$X_t = \varepsilon_t \quad \text{e} \quad Y_t = (-1)^t \varepsilon_t, \quad \forall\ t \in \mathbb{Z}.$$

(a) Prove que X e Y são fracamente estacionários.

(b) Mostre que o processo $(Z_t = X_t + Y_t :\ t \in \mathbb{Z})$ é um processo não estacionário.

Exercício 1.4. Considere um processo estocástico $Y = (Y_t : t \in \mathbb{Z})$ tal que $Y_t = \varepsilon_t - \theta \varepsilon_{t-1}$, $\theta \in [-1, 1]$, onde $(\varepsilon_t : t \in \mathbb{Z})$ é um ruído branco gaussiano de variância $\sigma^2 > 0$.

(a) Defina processo gaussiano e mostre que Y é gaussiano.

(b) Determine a distribuição da variável aleatória Y_t, $\forall\ t \in \mathbb{Z}$.

(c) Determine a função de autocorrelação de Y.

(d) O que pode concluir quanto à estacionariedade forte e fraca de Y?

Exercício 1.5. Seja $X = (X_t :\ t \geq 0)$ um processo estocástico, definido sobre o espaço de probabilidade $(\Omega, \mathcal{F}, P)$, tal que, para todo $t \geq 0$, $X_t \sim \mathcal{N}(0, t)$, e $P(X_0 = 0) = 1$.

(a) Diga em que condições será X um processo de incrementos independentes e estacionários.

(b) Supondo que X é um processo de incrementos independentes e estacionários, mostre que: (i) $\forall\ t, s \in [0, +\infty[$, com $t > s$, tem-se que $X_t - X_s \sim \mathcal{N}(0, |t - s|)$; (ii) X é um processo gaussiano centrado.

(c) Considere o processo estocástico $Y = (Y_t : t \geq 0)$ tal que:

$$Y(t) = \begin{cases} t, & X_t \geq 0 \\ -t, & X_t < 0. \end{cases}$$

Mostre que Y é um processo estocástico de segunda ordem centrado. Será Y estacionário em algum sentido? Justifique.

Exercício 1.6. Sejam $X = (X_t :\ t \in \mathbb{Z})$ e $(\varepsilon_t :\ t \in \mathbb{Z})$ dois processos estocásticos definidos sobre o espaço de probabilidade $(\Omega, \mathcal{F}, P)$, tais que:

$$\forall\ t \in \mathbb{Z}, \quad X_t = \sum_{j=0}^{+\infty} \left(\frac{4}{5}\right)^j \varepsilon_{t-j}.$$

(a) Explique em que condições será ε um ruído branco.

(b) Suponha que ε é um ruído branco tal que $E[\varepsilon_t^2] = 9/50$. (i) Prove que X é fracamente estacionário e indique as respetivas função média e função de autocovariância; (ii) Suponha agora que X é um processo gaussiano. Indique a distibuição do vector aleatório $(X_t, X_s),\ \forall\ t, s \in \mathbb{Z}$.

(c) Considere o processo estocástico $Y = (Y_t : t \in \mathbb{Z})$ tal que:

$$Y_t = \begin{cases} 1/2, & X_t \geq 0 \\ -1, & X_t < 0, \end{cases}$$

admitindo que X está nas condições da alínea b) ii). Calcule a função média de Y e mostre que Y é fracamente estacionário.

Exercício 1.7. Seja $(\varepsilon_t : t \in \mathbb{Z})$ um ruído branco gaussiano de variância $\sigma^2 > 0$. Considere um outro processo estocástico $(Y_t :\ t \in \mathbb{Z})$ definido por:

$$Y_t = \varepsilon_t - \theta\varepsilon_{t-1} - \frac{\theta}{2}\varepsilon_{t-2}, \quad \theta \in [-1, 1].$$

(a) Defina processo gaussiano e mostre que Y é gaussiano.

(b) Determine a função de autocorrelação do processo Y.

1.2.4 Martingalas

Do ponto de vista da modelação, as martingalas são apropriadas para modelar fenómenos aleatórios, tais como jogos de azar.

Definição 1.10 (Martingala)**.** Um PE $\{X_t, t \in T\}$ é uma **Martingala** sse:

- $E(\mid X_t \mid) < +\infty$;
- $\forall\ n \in \mathbb{N},\ \forall\ t_1 < ... < t_{n+1} \in T : E(X_{t_{n+1}} \mid X_{t_1}, ... X_{t_n}) = X_{t_n}$.

Exemplo 1.5. Considere-se E discreto e $T = \mathbb{N}$. Se interpretarmos X_n como a fortuna de um jogador após a realização do $n-$ésimo jogo, então a 2ª condição da definição anterior estabelece que a fortuna **esperada** após a $(n+1)-$ésima partida do jogo é igual à fortuna depois do $n-$ésimo jogo, independentemente do que ocorreu anteriormente.

Nota . Na definição de Martingala, podemos ainda considerar,

- Submartingalas, quando $\forall\ n \in \mathbb{N},\ \forall\ t_1 < ... < t_{n+1} \in T : E(X_{t_{n+1}} \mid X_{t_1}, ... X_{t_n}) \leq X_{t_n}$.
- Supermartingalas, quando $\forall\ n \in \mathbb{N},\ \forall\ t_1 < ... < t_{n+1} \in T : E(X_{t_{n+1}} \mid X_{t_1}, ... X_{t_n}) \geq X_{t_n}$.

Exercício 1.8.

Sejam $X_0, X_1, ...$ v.a.'s independentes com média nula e $S_= \sum_{i=0}^{n} X_i$. Mostre que o PE $\{S_n :\ n \in \mathbb{N}_0\}$ é uma Martingala.

Exercício 1.9.

Considere um jogo em cada em cada jogada o jogador pode ganhar ou perder com igual probabilidade. Após n jogadas o ganho desse jogador é dado por $S_= \sum_{i=i}^{n} X_i$, onde $X_1, X_2, ...$ são v.a.'s independentes. Mostre que o PE $\{S_n :\ n \in \mathbb{N}\}$ é uma Martingala.

Exercício 1.10.

Sejam $X_1, X_2, ...$ são v.a.'s independentes com média unitária. Mostre que o PE $\{Z_n :\ n \in \mathbb{N}\}$, definido por

$$Z_n = \prod_{i=1}^{n} X_i$$

é uma Martingala.

Exercício 1.11. Seja $(X_n,\ n = 0, 1, 2, \dots)$ um PE com espaço de estados $\mathbb{N}_0$, com média unitária para $n \geq 1$, com incrementos independentes e tal que $P(X_0 = 0) = 1$.

(a) O que significa dizer que o processo X tem incrementos independentes?

(b) Prove que o processo $(X_n,\ n = 0, 1, 2, \dots)$ é uma Martingala.

(c) Sabendo que $Var(X_n) = 1$, o que pode afirmar quanto à estacionariedade fraca do processo $(X_n,\ n = 0, 1, 2, \dots)$?

1.2.5 Processos de Markov

Definição 1.11 (Processo de Markov)**.** Um PE $\{X_t, t \in T\}$ com espaço de estados E diz-se um **processo de Markov** (ou **Markoviano**) sse $\forall\ n \in \mathbb{N},\ \forall\ t_1 < \dots < t_{n+1} \in T,\ \forall\ x_1 < \dots < x_{n+1} \in E,\ \forall\ B \in \mathcal{B}$:

$$P(X_{t_{n+1}} \in B \mid X_{t_1} = x_1, \dots X_{t_n} = x_n) = P(X_{t_{n+1}} \in B \mid X_{t_n} = x_n).$$

Nota . Os processos de Markov são apropriados na modelação de fenómenos aleatórios cujo comportamento futuro não é alterado pelo conhecimento do seu passado, apenas interessa conhecer o estado presente, ou seja, a probabilidade de que o sistema físico esteja num determinado estado num dado instante t pode deduzir-se a partir do conhecimento desse estado num instante qualquer anterior e essa probabilidade não depende da "história" do sistema antes de t.

Teorema 1.2. *Se E for discreto e $T = \mathbb{N}$, a propriedade de Markov da definição anterior é equivalente à seguinte:*

$$\forall\ n \in \mathbb{N},\ \forall\ x_0 < \dots < x_{n+1} \in E : P(X_0 = x_0, \dots, X_n = x_n) > 0, \textit{ tem-se que}$$

$$P(X_{n+1} = x_{n+1} \mid X_0 = x_0, \dots X_n = x_n) = P(X_{n+1} = x_{n+1} \mid X_n = x_n).$$

Nota . Os processos de Markov, como quaisquer processos, são classificados de acordo com a natureza do espaço de estados E e do espaço dos parâmetros T. Uma classe especial de processos de Markov são as **Cadeias de Markov** (C.M.): processos de Markov com espaço de estados E **discreto**.

Assim, uma cadeia de Markov pode interpretar-se com um PE cujo desenvolvimento se pode considerar como uma série de transições entre valores determinados que têm a propriedade de que a distribuição de probabilidade do estado futuro do processo, sabendo-se que ele está num dado estado, depende apenas deste estado e não do modo do meu como o processo lá chegou. As C.M. são classificadas em **discretas** ou **contínuas**. Nesta UC iremos abordar ambos os casos.

Capítulo 2

Cadeias de Markov em tempo discreto

2.1 Introdução

Uma cadeia de Markov em tempo discreto, $\{X_t, t \in T\}$, é um PE de Markov cujo espaço de estados é **finito** ou **infinito numerável**.

2.1.1 Conceitos básicos

Definição 2.1 (Cadeia de Markov em tempo discreto)**.** Um PE em tempo discreto $(X_n,\ n \in \mathbb{N}_0)$ com espaço de estados E discreto é uma **C.M. em tempo discreto** sse satisfaz a propriedade de Markov

$$\forall\ n \in \mathbb{N},\ \forall\ x_0 < ... < x_{n+1} \in E^{n+1} : P(X_0 = x_0, \dots, X_n = x_n) > 0, \text{tem-se que}$$

$$P(X_{n+1} = x_{n+1} \mid X_0 = x_0, ... X_n = x_n) = P(X_{n+1} = x_{n+1} \mid X_n = x_n).$$

Exercício 2.1. Seja $(X_n,\ n = 1, 2, \dots)$ uma sucessão de variáveis aleatórias i.d.d. com distribuição de probabilidade definida por:

$$P(X_n = n) = p(1-p)^x, \quad x = 0, 1, 2, \dots;\ p \in (0, 1).$$

Considere ainda o PE

$$Y = (Y_n = \sum_{i=1}^{n} X_i :\ n = 1, 2, \dots).$$

(a) Identifique o espaço de estados de Y.

(b) Mostre que $P(Y_{n+1} = y \mid Y_n = x)$ é independente de n.

(c) Verifique que Y é uma Cadeia de Markov.

(d) Calcule $P(Y_1 = y_1, Y_3 = y_3)$.

Exercício 2.2. Seja $(X_n,\ n = 1, 2, \dots)$ uma sucessão de variáveis aleatórias i.d.d. com distribuição de probabilidade definida por:

$$P(X_n = 1) = p = 1 - P(X_n = -1), \quad n = 1, 2, \dots;\ p \in (0, 1).$$

Considere o PE $S = (S_n :\ n \geq 0)$, conhecido como passeio aleatório simples, definido por:

$$S_0 = 0 \quad \text{e} \quad S_n = \sum_{i=1}^{n} X_i,\ n = 1, 2, \dots$$

(a) Identifique o espaço de estados do processo S.

(b) Prove que S é uma Cadeia de Markov para qualquer valor de p.

(c) Determine para que valores de p, o passeio aleatório S é uma Martingala.

(d) Calcule a função de autocovariância do processo S e verifique se o processo é estacionário em sentido estrito.

Associada a uma C.M. em tempo discreto tem-se a **função de probabilidade de transição a um passo**:

$$P(X_{n+1} = j \mid X_n = i) := P_{ij}(n, n+1),$$

que representa a probabilidade de X_{n+1} estar no estado j sabendo que no estado n a cadeia estava no instante i.

Se as probabilidades $P_{ij}(n, n+1)$ não dependerem de n, então a C.M. em tempo discreto diz-se **homogénea**. Assim, numa C.M. homogénea observa-se

$$P(X_{n+1} = j \mid X_n = i) := P_{ij}, \ \forall \ i, j \in E, \ \forall \ n \in \mathbb{N}_0.$$

Nota . A expressão $P(X_{n+1} = j \mid X_n = i) := P_{ij}$:

- representa a probabilidade de cadeia ir do estado i para o estado j **num só passo**;
- é independente de n, isto é, é homogénea no tempo.

Nesta UC apenas iremos estudar C.M. homogéneas. As probabilidade de transição, P_{ij} são fundamentais para o estudo da estrutura probabilística das C.M.

Definição 2.2 (Matriz de transição)**.** Define-se **Matriz de transição** ou **Matriz de probabilidade de transição** de uma C.M. homogénea à matriz

$$\mathbb{P} = [P_{ij}]_{\ i,j \in E} = \begin{bmatrix} P_{00} & P_{01} & \dots & P_{0j} & \dots \\ P_{10} & P_{11} & \dots & P_{1j} & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ P_{i0} & P_{i1} & \dots & P_{ij} & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{bmatrix}, \qquad E = \mathbb{N}_0$$

definida pelas probabilidades de transição P_{ij} do processo.

Nota . Na matriz de transição $\mathbb{P}$, observa-se:

- $P_{ij} \geq 0, \ i, j = 0, 1, \dots$, uma vez que P_{ij} representa uma probabilidade;
- $\sum\limits_{j=0}^{+\infty} P_{ij} = 1$, uma vez que $\sum\limits_{j \in E} P_{ij} = \sum\limits_{j \in E} P(X_{n+1} = j \mid X_n = i)$.

Exercício 2.3. Quatro bolas, duas brancas e duas pretas, são distribuídas em duas caixas A e B, de tal forma que, em cada caixa, ficam duas bolas. Tira-se uma bola de cada caixa e coloca-se cada uma na caixa oposta. Seja X_0 o número de bolas brancas que existiam inicialmente na caixa A. Para $n \geq 1$, seja X_n o número de bolas brancas que existirá na caixa A depois de se terem efetuado n trocas de bolas.

(a) Identifique o espaço de estados.

(b) Determine a matriz das probabilidades de transição.

Teorema 2.1. *Um PE $(X_t, \ t \in \mathbb{N}_0)$ é uma C.M. homogénea sse existe uma distribuição de X_0 e uma matriz estocástica $\mathbb{P}$ tal que:*

$$\forall \ (i_0, i_1, \dots, i_n) \in \mathbb{N}_0^{n+1} : P(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = P(X_0 = i_0) P_{i_0 i_1} \dots P_{i_{n-1} i_n}.$$

Este Teorema mostra que a distribuição do vetor aleatório $(X_0, X_1, \dots, X_n)$ fica completamente determinada se conhecermos a distribuição inicial de X_0 e matriz de transição $\mathbb{P}$.

Exemplo 2.1 (Passeio aleatório (deslocação de um ponto no plano))**.** Seja a sucessão $(Y_n,\ n \in \mathbb{N}_0)$ de v.a.'s independentes tomando valores em $\mathbb{Z}$ e, com exceção da 1ª variável Y_0, as restantes possuem a mesma lei de probabilidade $p = p(x),\ \forall\, x \in \mathbb{Z}$. O processo

$$\Big(X_n = \sum_{m \leq n} Y_m,\ n \in \mathbb{N}_0\Big)$$

chama-se **passeio aleatório** de estado inicial X_0 e distribuição unidimensional p.

Exercício 2.4.

Mostre que o processo aleatório definido no exemplo anterior é uma C.M. homogénea com matriz de transição com probabilidades

$$P_{xy} = p(y - x),\ \forall\ (x, y) \in \mathbb{Z}.$$

Exemplo 2.2 (Passeio aleatório unidimensional)**.** Um passeio aleatório a uma dimensão é uma C.M. cujo espaço de estados é um conjunto finito ou infinito numerável de inteiros, no qual a partícula estando no estado i, pode deslocar-se, numa transição, para o estado $i+1$, $i-1$, ou permanecer no estado i, isto é,

$$P(X_{n+1} = j \mid X_n = i) = \begin{cases} q_i, & j = i-1 \\ r_i, & j = i, \\ p_i, & j = i+1. \end{cases}$$

A matriz de transição é definida por

$$\mathbb{P} = \begin{bmatrix} r_0 & p_0 & 0 & 0 & \dots \\ q_1 & r_1 & p_1 & 0 & \dots \\ 0 & q_2 & r_2 & p_2 & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{bmatrix},$$

onde $q_i > 0,\ r_i > 0,\ p_i > 0;\ q_i + r_i + p_i = 1,\ i = 1, 2, \dots;\ p_0 \geq 0,\ r_0 \geq 0:\ r_0 + p_0 = 1.$

Em particular, quando no instante n o processo está no estado i, isto é, quando $X_n = i$, observa-se:

- $P(X_{n+1} = i+1 \mid X_n = i) = p_i$;
- $P(X_{n+1} = i-1 \mid X_n = i) = q_i$;
- $P(X_{n+1} = i \mid X_n = i) = r_i$.

Exemplo 2.3 (Versão discreta do movimento Browniano)**.** Trata-se de um caso particular do passeio aleatório unidimensional com:

$$q_i = q,\ r_i = r,\ p_i = p,\ \forall\ i.$$

Interpretação: uma partícula, no instante t, pode efetuar 3 movimentos:

- deslocar-se para a direita com probabilidade p;
- deslocar-se para a esquerda com probabilidade q;
- manter-se na mesma posição com probabilidade r;

Se X_n representar a posição da partícula ao fim de n movimentos, tem-se

$$X_n = \sum_{i=0}^{n} Y_i,$$

onde

$$Y_i = \begin{cases} 1, & \text{partícula deslocou-se para a direita,} \\ -1, & \text{partícula deslocou-se para a esquerda,} \\ 0, & \text{partícula não se deslocou.} \end{cases}$$

O que representam os processos X e Y?

- $(Y_n,\ n \in \mathbb{N}_0)$: sucessão de v.a.'s independentes (são independentes da posição X_n da partícula);

- $(X_n,\ n \in \mathbb{N}_0)$: passeio aleatório, isto é, CM homogénea, com espaço de estados $\mathbb{Z}$ e matriz de transição $\mathbb{P}$ onde:

$$P_{ij} = P(X_n = j \mid X_{n-1} = i) = \begin{cases} p, & j = i+1, \\ q, & j = i-1, \\ r, & j = i. \end{cases}$$

Assim, $P_{ij} = p(j-i)$ representa a lei de probabilidade (distribuição de probabilidade) de Y_n. Tipicamente considera-se $p = q = 0.5$ e $r = 0$.

Nota . Notação:

$$P_{ij}^m = P(X_{n+m} = j \mid X_n = i)$$

representa a probabilidade de, em m passos, a cadeia de Markov homogénea passar do estado i para o estado j.

Teorema 2.2. *Seja $\mathbb{P} = [P_{ij}]$ a matriz de transição a um passo de uma C.M. $(X_n,\ n \in \mathbb{N}_0)$. Então,*

$$P_{ij}^m = \sum_{k=0}^{+\infty} P_{ik}^r\ P_{kj}^s,$$

onde $(r,s) \in \mathbb{Z}^2$ tal que $r + s = m$ e $P_{ij}^0 = 1$ se $i = j$, e $P_{ij}^0 = 0$ se $i \neq j$.

Exercício 2.5.

Considere $m = 2$ e prove o Teorema anterior.

Teorema 2.3 (Equações de Chapman-Kolmogorov)**.** *O Teorema anterior pode ser re-escrito como*

$$P_{ij}^{m+n} = \sum_{k \in E} P_{ik}^m\ P_{kj}^n, \quad \forall\ i,j \in E.$$

Assim, $P_{i,j}^m$ representa o elemento (i,j) da matriz potência de ordem m de $\mathbb{P}$.

2.2 Classificação de estados de uma C.M.

Torna-se importante o estudo limite de $P_{i,j}^n$ quando $n \to +\infty$. Espera-se que a influência do estado inicial i diminua com o tempo, e que o limite de $P_{i,j}^n$ quando $n \to +\infty$ seja independente de i.

Para se poder analisar o comportamento assintótico do processo, vamos introduzir alguns critérios de classificação de estados de uma C.M.. Consideremos, no que se segue, uma C. M. $(X_n, n \in \mathbb{N}_0)$ com matriz de transição $\mathbb{P} = [P_{i,j}],\ i,j \in E$.

Definição 2.3 (Estado acessível)**.** Diz-se que o estado $j \in E$ é **acessível** a partir do estado $i \in E$, se para algum $n \in \mathbb{N}_0$ se observa $P_{ij}^n > 0$. Representação:

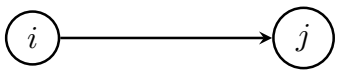

Figure 2.1: Estado acessível

Definição 2.4 (Estados em comunicação)**.** Se dois estados $i,j \in E$ são acessíveis um relativamente ao outro, diz-se que intercomunicam ou que estão **em comunicação**. Representação:

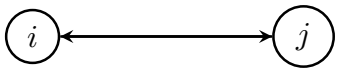

Figure 2.2: Estados em comunicação

Nota . Se dois estados $i, j \in E$ não comunicam, então:

$$\forall\ n \in \mathbb{N}_0,\ P_{ij}^n = 0\ \vee\ P_{ji}^n = 0.$$

Teorema 2.4. *A intercomunicação dos estados define uma relação de equivalência.*

Exercício 2.6.

Mostre o Teorema anterior. Sugestão: mostre que a intercomunicação entre estados é reflexiva, simétrica e transitiva.

Nota . A relação de equivalência do último Teorema induz uma partição do conjunto de todos os estados em classe de equivalência. Dentro de cada classe todos os estados comunicam entre si.

Exemplo 2.4. Considere a seguinte matriz de transição, com $E = \{0, 1, 2, \dots, r\}$, de um passeio aleatório:

$$\mathbb{P} = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 & 0 \\ q & 0 & p & 0 & \dots & 0 & 0 \\ 0 & q & 0 & p & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & q & 0 & p \\ 0 & 0 & 0 & 0 & \dots & 0 & 1 \end{bmatrix}.$$

A relação de equivalência de comunicação induz as classes:

$$\{0\},\ \{1, 2, \dots, r-1\},\ \{r\},$$

donde se conclui que: do estado 0 só se pode ir para o estado 0; todos os estados $1, 2, \dots, r-1$ comunicam entre si; do estado r só se pode ir para o estado r. Para $r = 5$, isto é, 6 estados, a matriz de transição é:

$$\mathbb{P} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ q & 0 & p & 0 & 0 & 0 \\ 0 & q & 0 & p & 0 & 0 \\ 0 & 0 & q & 0 & p & 0 \\ 0 & 0 & 0 & q & 0 & p \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

e a representação gráfica é:

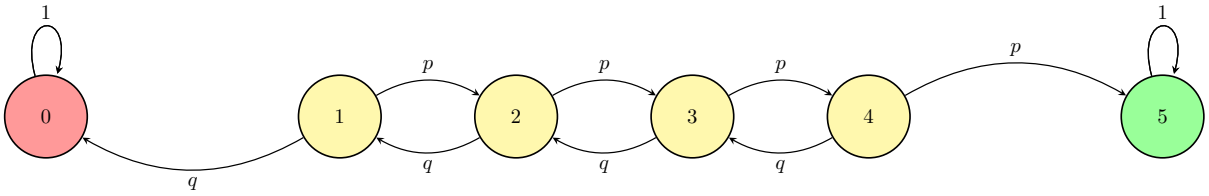

As classes de equivalência estão representadas por cores.

Definição 2.5 (Período)**.** Chama-se **período** do estado i, e representa-se por $d(i)$, ao máximo divisor comum de todos os inteiros $n \geq 1$ tais que $P_{ii}^n > 0$, isto é,

$$d(i) = \text{m.d.c.}(n \geq 1 : P_{ii}^n > 0).$$

Convenção: se $\forall\ n \geq 1, P_{ii}^n = 0$, então $d(i) = 0$.

Nota . Dois estados em comunicação têm o mesmo período, isto é,

$$i \longleftrightarrow j \iff d(i) = d(j).$$

Exercício 2.7. Determine o período dos estados do exemplo anterior.

Exercício 2.8. Considere a C.M. de espaço de estados finito com matriz de transição

$$\mathbb{P} = \begin{bmatrix} 0 & 1 & 0 & ... & 0 \\ 0 & 0 & 1 & ... & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & ... & 1 \\ 1 & 0 & 0 & ... & 0 \end{bmatrix}, \quad E = \{0, 1, ..., n-1\}.$$

Mostre que $d(i) = n, \ \forall \ n \in E$.

Definição 2.6 (Estado aperiódico)**.** Um estado diz-se **aperiódico** se tem período um.

Definição 2.7 (Estado recorrente)**.** Um estado diz-se **recorrente** sse $\exists \ n \geq 1 : P_{ii}^n = 1$, isto é, o processo sai do estado i e chega ao estado i.

Definição 2.8 (Estado transiente)**.** Um estado diz-se **transiente** sse $\forall \ n \geq 1 : P_{ii}^n < 1$, isto é, o processo sai do estado i mas não é certo que chegue a i.

Definição 2.9 (Tempo mínimo de passagem)**.** Considere-se a v.a. T_{ij} = tempo mínimo de passagem do estado i ao estado j, isto é,

$$T_{ij} = \min\{n : \ X_n = j \mid X_0 = i\}.$$

A função de probabilidade da v.a. T_{ij} é

$$\begin{aligned} f_{ij}^n &= P(T_{ij} = n) \\ &= P(X_n = j \wedge X_m \neq j, \ m = 1, 2, ..., n-1 \mid X_0 = i) \\ &= \sum_{k \in E \setminus \{j\}} P_{ik} P_{kj}, \quad \forall n \in \mathbb{N}_0. \end{aligned}$$

Por outras palavras, f_{ij}^n representa a probabilidade de partindo de i, chegar pela primeira vez a j na $n-$ésima transição.

Naturalmente observa-se que

$$f_{ij}^1 = P_{ij} \text{ e } f_{ij}^0 = 0, \quad \forall \ i, j \in E, \ i \neq j.$$

Uma outra definição para T_{ij} pode ser o tempo de espera para a primeira chegada ao estado j a partir do estado i.

Teorema 2.5.

$$\forall \ n \in \mathbb{N} : P_{ij}^n = \sum_{k=1}^{n} f_{ij}^k P_{jj}^{n-k}.$$

Exercício 2.9. Faça a demonstração do Teorema anterior.

Teorema 2.6. *Considere-se a probabilidade:*

$$f_{ij} = P(\text{ partindo de } i, \text{ eventualmente chegar a } j, \text{ num número finito de passos}).$$

Então,

$$f_{ij} = \sum_{n=1}^{+\infty} f_{ij}^n,$$

isto é, f_{ij} representa a soma da probabilidade de sair de i, chegar a j, pela 1ª vez, em k passos, e

$$f_{ij} > 0 \iff j \text{ é acessível a partir de } i.$$

Definição 2.10 (Estado recorrente)**.** O estado i diz-se **recorrente** (ou persistente) sse

$$\sum_{n=1}^{+\infty} f_{ii}^n = 1,$$

isto é, dizer que o estado i é **recorrente** significa que, partindo de i, volta-se de certeza a i, num número finito de transições. Por outras palavras, há sempre a possibilidade de sair de i e chegar a i em n passos.

Em termos da v.a.

$$T_{ij} = \text{ tempo mínimo para transitar do estado } i \text{ para o estado } j,$$

uma vez que

$$f_{ij}^n = P(T_{ij} = n),$$

então a definição de recorrência pode ser reescrita como:

$$i \text{ é recorrente } \iff P(T_{ii} < +\infty) = 1.$$

Definição 2.11 (Estado transitório)**.** O estado i diz-se **transitório** sse

$$\sum_{n=1}^{+\infty} f_{ii}^n < 1,$$

isto é, partindo de i, existe uma probabilidade não nula de **não regressar** a i. Por outras palavras,

$$i \text{ é transitório } \iff P(T_{ii} < +\infty).$$

Muito usado para a verificação se um estado é recorrente é o seguinte Teorema:

Teorema 2.7 (Teorema de Abel)**.** *Um estado i é recorrente sse*

$$\sum_{n=1}^{+\infty} P_{ii}^n = +\infty.$$

Teorema 2.8 (Critério de recorrêcia e transitoriedade)**.**

$$\sum_{n=1}^{+\infty} P_{ii}^n = +\infty \iff i \text{ é recorrente.}$$

$$\sum_{n=1}^{+\infty} P_{ii}^n < +\infty \iff i \text{ é transitório.}$$

$$i \longleftrightarrow j \text{ e } i \text{ é recorrente} \implies j \text{ é recorrente.}$$

Nota . O último critério apresentado no Teorema anterior mostra que a recorrência é uma propriedade da classe, isto é, numa classe de equivalência todos os estados são recorrentes ou não são recorrentes. Consequentemente:

- de um estado recorrente só se podem alcançar estados recorrentes;
- o conjunto dos estados recorrentes forma num conjunto fechado.

Teorema 2.9. *Se i é um estado recorrente e se j é acessível a partir de i, então $f_{ij} = 1$.*

Resumo: classificação de estados

- Estado **recorrente**: $\exists\, n \geq 1 :\ P_{ii}^n = 1$, isto é, partindo de i, a cadeia volta a i num número finito de passos.
- Estado **transitório**: $\forall\, n \geq 1 :\ P_{ii}^n < 1$, isto é, existe probabilidade positiva de não regressar a i.

Resumo: critérios para estabelecer a recorrência/transitoriedade

- Critério 1:

$$\sum_{n=1}^{+\infty} f_{ii}^n = 1 \implies \text{estado recorrente.}$$

$$\sum_{n=1}^{+\infty} f_{ii}^n < 1 \implies \text{estado transitório.}$$

- Critério 2:

$$P(T_{ii} < +\infty) = 1 \implies \text{estado recorrente.}$$

$$P(T_{ii} < +\infty) < 1 \implies \text{estado transitório.}$$

- Critério 3:

$$\sum_{n=0}^{+\infty} P_{ii}^n = +\infty \implies \text{estado recorrente.}$$

$$\sum_{n=0}^{+\infty} P_{ii}^n < +\infty \implies \text{estado transitório.}$$

Resumo: classificação de estados recorrentes

Defina-se $E[T_{ii}] = \mu_i = \sum_{n=1}^{+\infty} n f_{ii}^n$, isto é, μ_i representa o tempo de recorrência médio de um estado i (recorrente).

O estado i é:

- **recorrente positivo** se $\mu_i < +\infty$, isto é, o tempo médio de recorrência do estado i é finito;
- **recorrente nulo** se $\mu_i = +\infty$;
- **recorrente ergódico** se i for recorrente positivo e aperiódico.

Por último, temos o seguinte Teorema que ajuda a classificar os estado de uma cadeia de Markov:

Teorema 2.10. *Numa **cadeia de Markov irredutível** com espaço de estados finito ou infinito numerável, **ou** todos os estados são transitórios, **ou** todos os estados são recorrentes nulos, **ou** todos os estados são recorrentes positivos.*

Exercício 2.10. Seja $X_0, X_1, X_2, \ldots$ uma sucessão de variáveis aleatórias i.i.d.'s tal que:

$$P(X_i = -1) = P(X_i = 1) = 0.5, \quad i = 0, 1, 2, \ldots.$$

(a) Prove que $(X_n : n \in \mathbb{N}_0)$ é uma C.M. homogénea com matriz de transição

$$\mathbb{P} = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}.$$

(b) Determine a probabilidade de que o processo $(X_n : n \in \mathbb{N}_0)$, partindo do estado 1, volte a atingir este estado, pela primeira vez, num número par de passos.

(c) Considere o PE $(Y_n : n \in \mathbb{N})$ definido por:

$$Y_n = \begin{cases} X_{n-1} \cdot X_{n+1}, & n \text{ par} \\ X_n, & n \text{ ímpar} \end{cases}.$$

(d) Verifique se Y é um ruído branco e, em caso afirmativo, identifique a sua variância; (ii) Prove que Y não é uma C.M.

Exercício 2.11. Considere uma estação de táxis, onde de s em s segundos chega cum táxi. Se não existem clientes a ser servidos, o táxi parte de imediato, chegando outro s segundos depois. Caso contrário, os clientes vão sendo atendidos por ordem de chegada, havendo sempre um período de tempo constante de s segundos entre cada serviço. Durante esse período de tempo podem, no entanto, chegar novos clientes. Suponhamos que o número de chegadas ao $n-$ésimo período de tempo é uma variável aleatória Z_n cuja distribuição é independente do período em que ocorrem as chegadas, e é dada por

$$P(\text{k clientes chegarem num intervalo de tempo entre 2 chegadas consecutivas de táxi}) = a_k,$$

onde $a_k \geq 0,\ \forall\ k \in \mathbb{N}_0$, e $\sum\limits_{k=0}^{+\infty} a_k = 1$.

O estado do sistema no início do $(n+1)-$ésimo período de tempo entre duas chegadas consecutivas de táxi é definido pelo número de clientes que esperam para serem atendidos, sendo esse número representado por $X_n,\ n \in \mathbb{N}_0$.

(a) Prove que $\{X_n,\ n \in \mathbb{N}_0\}$ é uma C.M. homogénea. Indique os respetivos espaço de estados e matriz de transição.

(b) Sabendo que no início de um determinado intervalo a fila tem zero clientes, qual a probabilidade de o sistema voltar a atingir este estado (pela primeira vez) ao fim de três chegadas de táxis?

Exercício 2.12. Seja $\{Y_n,\ n \in \mathbb{N}\}$ uma sucessão de v.a.'s i.i.d. com distribuição $B(2; 0.5)$. Considere um PE $\{X_n,\ n \in \mathbb{N}_0\}$ definido por:

$$\forall\ n \in \mathbb{N},\ X_n = \begin{cases} \sum\limits_{i=1}^{X_{n-1}} Y_i, & X_{n-1} \geq a \\ a, & 0 \leq X_{n-1} \leq a \end{cases}, \quad X_0 = a,$$

com $a \in \mathbb{N}$, arbitrariamente fixo.

(a) Identifique o espaço de estados do processo X.

(b) Prove que X é uma C.M. homogénea e identifique a matriz de transição.

Exercício 2.13. Determinado ser vivo produz durante a sua vida um número de descendentes Y de acordo com uma distribuição dada por:

$$\forall\ k \in \mathbb{N}_0,\ P(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad \lambda > 0 \text{ constante.}$$

A cada indivíduo i da população associamos uma v.a. $Y_i =$ número de descendentes do indivíduo i. Para cada $n \in \mathbb{N}_0$, define-se a v.a. X_n que representa o tamanho da população na geração de ordem n. Considere o PE $(X_n :\ n \in \mathbb{N}_0)$.

(a) Prove que $(X_n :\ n \in \mathbb{N}_0)$ é uma C.M. homogénea.

(b) Calcule a probabilidade de existirem $k \in \mathbb{N}_0$ indivíduos na geração de ordem $n+2$, sabendo que na geração de ordem n existiam $j \in \mathbb{N}_0$.

Exercício 2.14. Considere lançamentos repetidos de um dado honesto. Seja X_n o máximo dos números que ocorreram nos n primeiros lançamentos.

(a) Indique o espaço de estados da C.M. $(X_n :\ n \in \mathbb{N}$ e a respetiva matriz de transição.

(b) Determine $P(X_i = i),\ i = 1, 2, \ldots, 6$ e $P(X_2 = 3)$.

(c) Desenhe o grafo da cadeia, classifique os seus estados, e analise o tipo de recorrência.

(d) Verifique que a cadeia é aperiódica.

Exercício 2.15. Seja $(X_n :\ n \in \mathbb{N})$ uma C.M. com espaço de estados $E = \mathbb{N}_0$ e probabilidades de transição P_{ij} tais que:

$$P_{k0} = \frac{1}{k+2} \quad \text{e} \quad P_{k,k+1} = \frac{k+1}{k+2}.$$

Mostre que a cadeia é irredutível.

Exercício 2.16. Seja $(Z_n : n \in \mathbb{N}_0)$ uma C.M. homogénea com espaço de estados $E = \mathbb{N}_0$ e probabilidades de transição:

$$\mathbb{P} = \begin{bmatrix} 1-a_0 & a_0 & 0 & 0 & ... \\ 1-a_1 & 0 & a_1 & 0 & ... \\ 1-a_2 & 0 & 0 & a_2 & ... \\ ... & ... & ... & ... & ... \end{bmatrix}, \quad 0 < a_i < 1, \ i = 0, 1, 2, ...$$

(a) A cadeia dada é irredutível e aperiódica? Justifique.

(b) Determine a probabilidade f_{00}^n de que a cadeia, partindo do estado 0, volte novamente a esse estado, pela primeira vez, em n passos. De seguida, mostre que:

$$\sum_{n=1}^{M+1} f_{00}^n = 1 - \prod_{i=0}^{M} a_i.$$

(c) Atendendo aos resultados das alíneas anteriores, enuncie, em termos dos a_i's, uma condição necessária e suficiente para que todos os estados sejam recorrentes. Justifique a sua resposta.

Exercício 2.17. Uma dada empresa identificou seis estados associados ao comportamento diário dos seus colaboradores: $0, 1, 2, 3, 4, 5$. As transições de estado para estado podem ser modeladas por uma C.M. com matriz de transição:

$$\mathbb{P} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0.1 & 0 & 0.5 & 0.3 & 0 & 0.1 \\ 0 & 0 & 0 & 0.7 & 0.1 & 0.2 \\ 0.3 & 0 & 0 & 0.3 & 0.4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

(a) Desenhe o grafo de $\mathbb{P}$.

(b) Identifique os estados transitórios e os estados recorrentes.

2.2.1 Decomposição do espaço de estados

Agora pretendemos decompor o espaço de estados de uma cadeia de Markov finita em subclasses. O objetivo é estudar propriedades da cadeia pela análise das propriedades de cada classe separadamente.

Definição 2.12 (Conjunto fechado)**.** Seja um C.M. com espaço de estados E e matriz de transição $\mathbb{P} = [P_{ij}]_{i,j \in E}$. Diz-se que um conjunto $C \subset E$ é **fechado** sse

$$\forall \ i \in C, \ \forall \ \ j \notin C, \ P_{ij}^n = 0, \ \forall \ n \in \mathbb{N},$$

ou seja, sse nenhum estado **não pertencente** a C é acessível a partir de qualquer estado do conjunto C. Isto quer dizer que:

- não existem "setas" de dentro para fora de C;
- uma classe de estados não é necessariamente um conjunto fechado.

Definição 2.13 (Classe fechada)**.** Um conjunto fechado diz-se ser uma **classe fechada** sse todos os estados do conjunto fechado comunicam entre si. Note-se que, uma vez que a cadeia de Markov "entre" numa classe fechada nunca mais de lá sai.

Coloca-se agora a questão: como se encontram todos os estados que pertencem a uma classe fechada (ou a um conjunto fechado)? Resposta: seguem-se os passos seguintes:

- Passo 1: inclui-se em C todos os estados j para os quais $P_{ij} > 0$, isto é, $i \longrightarrow j$;
- Passo 2: inclui-se em C todos os estados k para os quais $P_{jk} > 0, \ \forall \ j \in C$, isto é, $i \longrightarrow k$ (propriedade da transitividade);
- Passo 3: repetir o Passo 2 até não se poder incluir mais estados em C.

O resultado seguinte permite uma decomposição do espaço de estados de uma C.M., chamada **decomposição canónica**.

Teorema 2.11 (Decomposição canónica). *O espaço de estados E de uma C.M. pode ser decomposto numa união finita ou infinita numerável do seguinte modo:*

$$E = T \cup C_1 \cup C_2 \cup \dots,$$

onde:

- *T representa o conjunto de estados transitórios;*
- *$C_1, C_2, \dots$ representa as classes fechadas disjuntas de estados recorrentes tais que*

$$\forall\ j \in C_a : \sum_{n=1}^{+\infty} f_{jk}^n = \begin{cases} 1, & k \in C_a, \\ 0, & k \notin C_a, \end{cases}$$

onde o somatório representa a probabilidade de, partindo de j, chegar a k num número finito de passos.

Adicionalmente, a matriz de transição pode ser re-escrita da forma

$$\mathbb{P} = \begin{bmatrix} P_1 & 0 & 0 & \dots \\ 0 & P_2 & 0 & \dots \\ 0 & 0 & P_3 & \dots \\ \vdots & \vdots & \vdots & \vdots \\ Q_1 & Q_2 & Q_3 & \dots \end{bmatrix},$$

onde:

- *$P_1, P_2, \dots$ são matrizes estocásticas que se obtêm de $\mathbb{P}$ por eliminação de todas as linhas e colunas correspondentes aos estados que não estão em $C_1, C_2, \dots$, isto é, $\mathbb{P}_a = [P_{ij}]_{i,j \in C_a},\ a = 1, 2, \dots$.*
- *os estados de transição de T são governados pelas matrizes $Q_1, Q_2, \dots$.*

Nota . Em particular, a classificação dos estados de uma C.M. com espaço de estados E finito, pode fazer-se da seguinte forma:

- Passo 1: decompor o espaço E em classes de equivalência;
- Passo 2: identificar as classes fechadas;
- Passo 3: nas classes fechadas, os estados são recorrentes positivos e nas não fechadas são transitórios.

Exemplo 2.5. Considere-se uma C.M com espaço de estados $E = \{1, 2, \dots, 7\}$ e com matriz de transição

$$\mathbb{P} = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 0 & 0 & 0 & 0 & 2/3 \\ 0 & 0 & 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 & 0 & 0 \\ 1/3 & 0 & 1/3 & 0 & 1/3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1/4 & 1/4 & 0 & 0 & 0 & 0 & 1/2 \end{bmatrix}.$$

- O grafo associado à matriz $\mathbb{P}$ é:

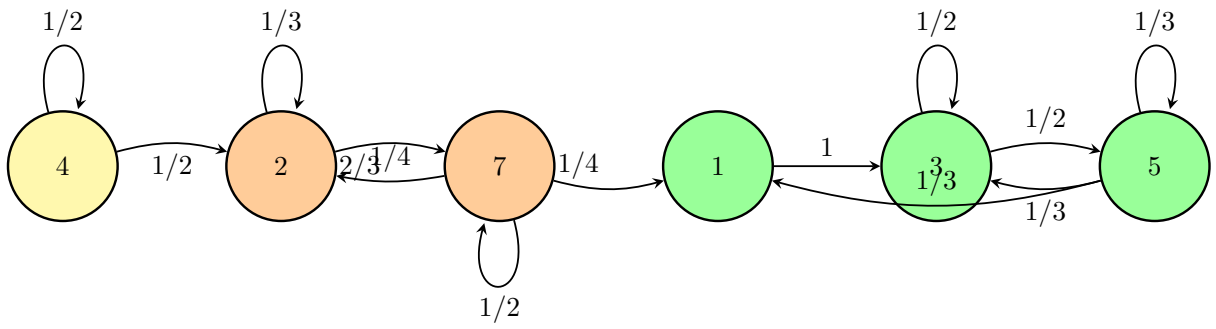

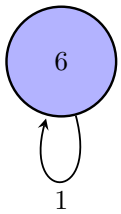

- As classes são: $\{1,3,5\},\{2,7\},\{4\},\{6\}$.
- Conjuntos fechados: $\{1,3,5\},\{2,7,1,3,5\},\{4,2,7,1,3,5\},\{6\}$.
- Classes fechadas: $\{1,3,5\},\{6\}$.
- Estados recorrentes positivos: $1,3,5,6$.
- Estados transitórios: $2,4,7$.
- Decomposição: $E = T \cup C_1 \cup C_2 = \{2,4,6\} \cup \{1,3,5\} \cup \{6\}$.
- A matriz de transição pode ser reescrita como:

$$\mathbb{P} = \left[\begin{array}{c|ccc|ccc} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ \hline 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 0 & 1/3 & 1/3 & 1/3 & 0 & 0 & 0 \\ \hline 0 & 0 & 0 & 0 & 1/3 & 0 & 2/3 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 1/4 & 0 & 0 & 1/4 & 0 & 3/4 \end{array}\right] = \begin{bmatrix} P_1 & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & P_2 & \mathbf{0} \\ Q_1 & Q_2 & Q_3 \end{bmatrix},$$

onde P_i representa a matriz de probabilidades de transição da classe C_i e Q_i é a matriz associada a estados de transição.

2.3 Probabilidades de absorção em estados recorrentes

Um dos cálculos de interesse na teoria das cadeias de Markov está relacionado com o tempo (ou número de transições) necessário, para que, a cadeia partindo de algum estado inicial, **atinja algum estado terminal de interesse**.

Este assunto está muitas vezes associado ao problema da determinação de probabilidades de absorção, com a seguinte formulação.

- Seja $E = T \cup C_1 \cup C_2 \cup \ldots$ a decomposição canónica do espaço de estados E, onde T é definido pelos estados transitórios da cadeia, e C_i são classes fechadas e recorrentes.
- Se a cadeia parte de um estado recorrente em C_a, nunca mais deixará C_a (C_a é fechada).
- Se a cadeia parte do estado transitório de T, a cadeia poderá ser absorvida por uma das classes $C_a,\ a = 1,2,\ldots$.

Nestas circunstâncias estamos interessados nas probabilidades de absorção:

Definição 2.14. Seja j um estado recorrente pertencente a uma classe fechada C_a e seja i um estado transitório de T. Considere-se a v.a.

$$S := \min\{n \geq 1 : X_n \in (C_1 \cup C_2 \cup \ldots)\}.$$

Então,

$$S \mid X_0 = i$$

representa o **tempo mínimo** de passagem do estado transitório i para o estado recorrente j, ou seja, representa o **tempo mínimo** para sair de T.

Assim, podemos definir

$$a_{ij} = P(X_S = j \mid X_0 = i), \quad j \in (C_1 \cup C_2 \cup \dots)$$

como a probabilidade da cadeia de, partindo do estado transitório i, ser **absorvida** pelo estado recorrente j.

Teorema 2.12. *Seja E um espaço de estados finito. As probabilidades de absorção a_{ij} podem ser determinadas com base no seguinte sistema de equações lineares*

$$a_{ij} = P_{ij} + \sum_{k \in T} P_{ik}\, a_{kj}, \quad i \in T,\ j \in (C_1 \cup C_2 \cup \dots).$$

*Interpretação: a absorção ocorre logo na primeira transição **ou** se não ocorrer num passo, então deve ser feita uma transição para um estado intermédio k, a partir do qual será absorvida pelo estado recorrente j.*

Exemplo 2.6. Num estudo no Reino Unido, após a Segunda Guerra Mundial, sobre a mobilidade social entre gerações foram identificados 3 níveis: 1 - superior, 2 - médio e 3 - inferior. Foram estimadas as probabilidades condicionais de um filho pertencer a uma classe social (nível superior, médio, ou inferior) mediante o nível social dos pais ser superior, médio ou inferior. Os resultados são apresentados na tabela seguinte:

	Filho		
Pai	Superior	Médio	Inferior
Superior	0.45	0.48	0.07
Médio	0.05	0.70	0.25
Inferior	0.01	0.50	0.49

Admitamos que as transições entre classes de gerações sucessivas é uma família que pode ser considerada como transições de uma cadeia de Markov.

1. Qual a probabilidade de um neto de uma família com nível médio seja o primeiro descendente a ser considerado com um nível social superior, isto é, qual o valor de f_{21}^2?
2. Qual a probabilidade de que, em alguma geração, de uma família com nível social inferior, seja atingida pela primeira vez o nível superior?

Solução

A matriz de transição é dada por

$$\mathbb{P} = \begin{bmatrix} 0.45 & 0.48 & 0.07 \\ 0.05 & 0.70 & 0.25 \\ 0.01 & 0.50 & 0.49 \end{bmatrix}, \quad E = \{1,2,3\} = \{2,3\} \cup \{1\} = T \cup C.$$

O grafo é

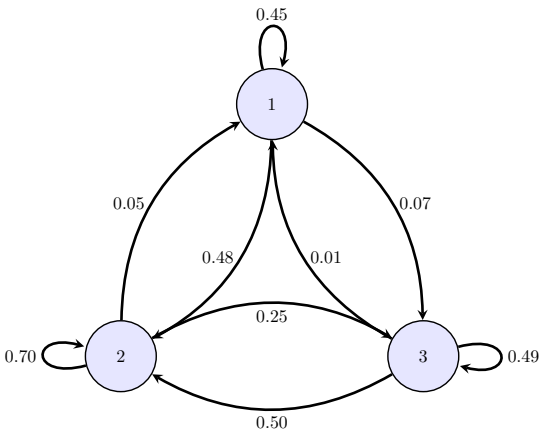

1. Pretende-se determinar a probabilidade de, começando no estado 2, o primeiro momento em que a cadeia entra no estado 1 seja no instante 2. Para tal, iremos usar a probabilidade de primeira passagem do estado 2 para o estado 1

em 2 passos, isto é,

$$\begin{aligned} f_{21}^2 &= P(X_2 = 1, X_1 \neq 1 \mid X_0 = 2) \\ &= P(X_2 = 1, X_1 = 2 \mid X_0 = 2) + P(X_2 = 1, X_1 = 3 \mid X_0 = 2) \\ &= \sum_{k \neq 1} P_{2k} P_{k1} \\ &= P_{22} P_{21} + P_{23} P_{31} \\ &= 0.70 \times 0.05 + 0.25 \times 0.01 \\ &= 0.0375. \end{aligned}$$

2. Nesta questão, estamos interessados no cálculo do tempo necessário para que a cadeia, partindo de um estado inicial ("nível social inferior"), atinja um estado terminal de interesse ("nível superior"). Podemos, portanto, utilizar as probabilidades de absorção e aplicar o Teorema 2.12. Assim,

$$a_{31} = P_{31} + \sum_{k \in T} P_{3k} a_{k1} = P_{31} + P_{32} a_{21} + P_{33} a_{31}.$$

Uma vez que não sabemos o valor de a_{21}, podemos resolver o sistema:

$$\begin{cases} a_{31} = P_{31} + P_{32} a_{21} + P_{33} a_{31} \\ a_{21} = P_{21} + P_{22} a_{21} + P_{23} a_{31} \end{cases},$$

donde se obtém $a_{31} = 1$ (e $a_{21} = 1$).

Exercício 2.18. Os negócios do José flutuam em anos sucessivos entre 3 estados: 0 (bancarrota), 1 (perto da bancarrota) e 2 (solvência). A matriz de transição que indica a probabilidade de passagem de um estado para outro é:

$$\mathbb{P} = \begin{bmatrix} 1 & 0 & 0 \\ 0.5 & 0.25 & 0.25 \\ 0.5 & 0.25 & 0.25 \end{bmatrix}.$$

(a) Qual a probabilidade dos negócios do José conduzirem a uma bancarrota sabendo que ele começou no estado de solvência?

(b) A mãe do José considera ser mau para o nome da família permitir que os negócios do seu filho vão à bancarrota. Assim, quando o estado 0 é atingido, a mãe do José dá-lhe dinheiro efetivo de modo a que os negócios do José passem ao eatdo de solvência com probabilidade 1. A matriz de transição desta nova cadeia de Markov é dada por:

$$\mathbb{P} = \begin{bmatrix} 0 & 0 & 1 \\ 0.5 & 0.25 & 0.25 \\ 0.5 & 0.25 & 0.25 \end{bmatrix}.$$

A nova cadeia de Markov é iredutível e aperiódica? Sabendo que os negócios do José estão a correr bem (estado 2), qual a probabilidade da mãe do José ter necessidade de dar novamente dinheiro ao filho apenas daqui a 3 anos?

Exercício 2.19. Num dado centro comercial existem 4 restaurantes A, B, C e D. Desde que a Ana trabalha numa das lojas do centro, ela almoça regularmente num dos 4 restaurantes. Sabe-se ainda que a escolha diária do restaurante está de acordo uma C.M. homogénea com matriz de transição:

$$\mathbb{P} = \begin{bmatrix} 0.5 & 0.5 & 0 & 0 \\ 0.3 & 0 & 0.1 & 0.6 \\ 0.4 & 0 & 0.3 & 0.3 \\ 0 & 0 & 1 & 0 \end{bmatrix}.$$

Sabe-se que no primeiro dia de trabalho qualquer um dos 4 restaurantes tinha igual probabilidade de ser selecionado pela Ana.

(a) Defina distribuição inicial de uma C.M. e indique a distribuição inicial da cadeia dada.

(b) Calcule a probabilidade de no segundo dia de trabalho a Ana selecione o restaurante B para almoçar.

(c) Classifique quanto à recorrência todos os estados da cadeia.

(d) Sabendo que a Ana almoçou hoje no restaurante B, qual a probabilidade da Ana nos próximos dias optar pelo restaurante A antes de selecionar o restaurante D?

(e) Qual o número médio de dias entre dois almoços no restaurante B?

2.4 Teoremas limite

2.4.1 Distribuição estacionária e distribuição limite

Seja $(X_n : n \in \mathbb{N}_0)$ uma C. M. definida num espaço de estados E, com matriz de transição $\mathbb{P}$ e distribuição inicial $P(X_0 = i),\ i \in E$. Existem duas questões pertinentes:

- Qual o comportamento de X_n após um "longo" número de transições?
- Poderá a cadeia atingir um "comportamento estável" após um "longo" número de transições?

Em geral, a sucessão de v.a.'s $(X_n : n \in \mathbb{N}_0)$ não converge para um estado específico, já que a cadeia goza da propriedade da flutuação aleatória inerente ao próprio processo definida pela matriz de transições. No entanto, pode acontecer que a distribuição de X_n estabilize de algum modo após um elevado número de transições.

Definição 2.15 (Distribuição limite)**.** Se existir

$$\lim_{n\to+\infty} P(X_n = j), \quad j \in E,$$

e esse limite, usualmente denotado por π_j, definir uma distribuição de probabilidade, então o vetor

$$\tilde{\pi} = (\pi_j, \quad j \in E)$$

designa-se por **distribuição limite** da cadeia.

O estudo da existência de uma distribuição limite da cadeia, nomeadamente de uma distribuição de probabilidade $(\pi_j, \quad j \in E)$, tal que

$$\forall\ j \in E, \quad \pi_j = \lim_{n\to+\infty} P(X_n = j)$$

está relacionado com a existência da chamada distribuição estacionária.

Definição 2.16 (Distribuição estacionária)**.** Diz-se que a C.M. possui **distribuição estacionária** se existir $\tilde{\pi} = (\pi_j, \quad j \in E)$ tal que:

(i) $\tilde{\pi}$ define uma distribuição de probabilidade ($\pi_j > 0,\ \forall\ j \in E$ e $\sum_{j\in E} \pi_j = 1$);

(ii) $\tilde{\pi} = \tilde{\pi}\ \mathbb{P}$, isto é,

$$\forall\ j \in E : \ \pi_j = \sum_{i\in E} \pi_i P_{ij}.$$

Nota .

1. $\tilde{\pi} = [\pi_0 \ \ \pi_1 \ \ \pi_2 \ \ \ldots]$ se $E = \mathbb{N}_0$.
2. A razão pela qual uma distribuição de probabilidade discreta $\tilde{\pi} = (\pi_j, \quad j \in E)$ que satisfaz (ii) é chamada de distribuição estacionária, tem a ver com o facto de

$$\begin{aligned} \tilde{\pi} = \tilde{\pi}\ \mathbb{P} \implies \tilde{\pi} &= (\tilde{\pi}\ \mathbb{P})\ \mathbb{P} = \tilde{\pi}\ \mathbb{P}^2 \\ &= (\tilde{\pi}\ \mathbb{P})\ \mathbb{P}^2 = \tilde{\pi}\ \mathbb{P}^3 \\ &= \ldots \\ &= \tilde{\pi}\ \mathbb{P}^n,\ \forall\ n \in \mathbb{N}. \end{aligned}$$

3. Por outro lado, pelas propriedades da distribuição das C. M., sabemos que a distribuição de X_n é dada por:

$$P(X_n = j) = \sum_{i\in E} P(X_0 = i) P_{ij}^n, \quad \forall\ n \in \mathbb{N}_0.$$

Assim, comparando as relações (2) e (3), se a distribuição inicial for a distribuição estacionária da cadeia, isto é, se

$$P(X_0 = i) = \pi_i,\ i \in E,$$

então a distribuição de probabilidade de X_n também é a distribuição estacionária da cadeia, ou seja,

$$P(X_n = j) = \pi_j,\ j \in E,\ n \in \mathbb{N}_0.$$

Consequentemente, nestas condições, teríamos:

- a distribuição de X_n é estacionária com a passagem do tempo (isto é, não se altera com o número de transições n);
- os vetores aleatórios
$$(X_{n_1}, \dots, X_{n_k}) \text{ e } (X_{n_1+m}, \dots, X_{n_k+m})$$
têm a mesma distribuição, isto é, a cadeia é um processo estritamente estacionário.

Do exposto, podemos observar o seguinte Teorema:

Teorema 2.13. *Se a C.M. tem distribuição estacionária $\tilde{\pi} = (\pi_j,\ j \in E)$ e a distribuição inicial da cadeia for também $\tilde{\pi}$, isto é,*
$$P(X_0 = i) = \pi_i,\ \forall i \in E,$$
então existe distribuição limite da cadeia e é dada por
$$\lim_{n \to +\infty} P(X_n = j) = \pi_j,\ j \in E.$$

Nota . Para n suficientemente elevado, se os X_n tiverem a mesma distribuição de probabilidade, e se tomarmos essa distribuição como a distribuição inicial, então a C.M. terá um comportamento estável após um elevado número de transições dos estados da cadeia.

Em que condições a C.M. tem distribuição estacionária? Atente-se ao seguinte Teorema:

Teorema 2.14. *Uma C.M. irredutível tem uma distribuição estacionária*
$$\tilde{\pi} = (\pi_j,\ j \in E),$$
sse os estados são todos recorrentes positivos. Neste caso, $\tilde{\pi}$ é a única distribuição estacionária e é dada por
$$\pi_j = \frac{1}{\mu_j},\ j \in E,$$
onde μ_j é o tempo médio de recorrência do estado j.

Nota . Este Teorema fornece um método para testar se uma C.M. irredutível é recorrente positiva. Para tal basta procurar a distribuição estacionária. Como se obtém esta distribuição?
$$\tilde{\pi} \text{ satisfaz: } \begin{cases} \tilde{\pi} = \tilde{\pi}\ \mathbb{P} \\ \sum_{j \in E} \pi_j = 1. \end{cases}$$
Se existir $\tilde{\pi_j}$ então a C.M. é recorrente positiva e $\pi_j = 1/\mu_j$.

Corolário 2.1. *Uma C.M. irredutível, recorrente positiva, e com distribuição inicial estacionária $\tilde{\pi} = (\pi_j,\ j \in E)$, tem distribuição limite dada por*
$$\pi_j = \lim_{n \to +\infty} P(X_n = j).$$

2.4.2 Comportamento limite de P_{ij}^n quando $n \to +\infty$

Qual a relação entre a existência de uma distribuição estacionária e o comportamento limite das probabilidades de transição a n passos, quando $n \to +\infty$?

Teorema 2.15. *Se existir uma distribuição de probabilidade $\tilde{\pi} = (\pi_j,\ j \in E)$, tal que*
$$\forall\ i, j \in E:\ \pi_j = \lim_{n \to +\infty} P_{ij}^n,$$
então,
$$(i) \quad \pi_j = \lim_{n \to +\infty} P(X_{ij}^n) \quad \textit{e}$$
$$(ii) \quad \tilde{\pi} \textit{ é distribuição estacionária.}$$

Nota . Pode acontecer que uma C.M. tenha uma única distribuição estacionária $\tilde{\pi}$, mas não ser a distribuição limite da cadeia, isto é, a cadeia pode não ser **estável**. No entanto, se esta distribuição estacionária única for tal que

$$\pi_j = \lim_{n\to+\infty} P_{ij}^n, \quad j \in E$$

então, necessariamente $\tilde{\pi}$ é a distribuição limite da C.M. Assim, podemos concluir que se existir o $\lim_{n\to+\infty} P_{ij}^n$, e se este definir uma distribuição de probabilidade, independentemente do estado inicial i, então essa distribuição definirá a distribuição limite da cadeia. Neste sentido, o estudo do comportamento limite da cadeia **não dependerá** da distribuição inicial $P(X_0 = i),\ i \in E$, mas apenas do comportamento limite das probabilidades de transição a n passos, quando $n \to +\infty$, ou seja, de

$$\lim_{n\to+\infty} P_{ij}^n, \quad \forall\ i,j \in E.$$

Mas existirá sempre este limite? Não! E, quando existe, como se calcula? Em geral, os cálculos para a obtenção de $\mathbb{P}^n$ são morosos e difíceis, principalmente para valores de n elevados.

Para contornar esta dificuldade, analisa-se o comportamento das probabilidades P_{ij}^n quando $n \to +\infty$. Caso estas sejam fáceis de obter, poderão ser utilizadas como aproximações das probabulidades de transição a um número finito de n passos, para n suficientemente elevado. Atente-se ao seguinte Teorema:

Teorema 2.16. *Se uma C.M. é irredutível, aperiódica, e recorrente, então*

$$\exists \lim_{n\to+\infty} P_{ij}^n \quad \text{e} \quad \lim_{n\to+\infty} P_{ij}^n = \lim_{n\to+\infty} P_{jj}^n = \frac{1}{\mu_j},\ \forall\ i,j \in E.$$

Teorema 2.17. *Em cadeias de Markov irredutíveis e aperiódicas, todos os seus estados são recorrentes positivos, isto é, a cadeia é* ***ergódica****:*

(i) sse o sistema de equações lineares

$$\begin{cases} \pi_j = \sum\limits_{i\in E} \pi_i\ P_{ij}, & j \in E, \\ \sum\limits_{j\in E} \pi_j = 1 \end{cases},$$

tiver solução

$$\pi = [\pi_0 \quad \pi_1 \quad \dots\ ],\ \text{com } E = \mathbb{N}_0.$$

(ii) se tiver solução, será única, estritamente positiva e,

$$\pi_j = \lim_{n\to+\infty} P_{ij}^n, \quad \forall\ i,j \in E.$$

Nota .

1. O Teorema 2.17 apresenta uma condição necessária e suficiente para que cadeira irredutível e aperiódica seja ergódica;
2. A solução do sistema, quando existir, é simultaneamente distribuição estacionária e distribuição limite.
3. Uma vez que

$$\lim_{n\to+\infty} P_{ij}^n = \pi_j,$$

pode-se aproximar a matriz $\mathbb{P}^n$ à matriz $[\pi_j]_{j\in E}$ para valores elevados de n.

Nota . Numa C.M. irredutível com um número finito de estados não pode haver nem estados transitórios, nem recorrentes nulos, pois em qualquer dos casos

$$\lim_{n\to+\infty} P_{ij}^n = 0.$$

Assim, numa C.M. irredutível finita, como todos os estados intercomunicam, eles serão todos recorrentes positivos. Atente-se ao Corolário seguinte.

Corolário 2.2. *Numa C.M. irredutível, aperiódica e finita, o sistema de equações lineares*

$$\begin{cases} \pi_i = \sum_{i \in E} \pi_i \, P_{ij}, \\ \sum_{j \in E} \pi_j = 1 \end{cases},$$

tem solução única, estritamente positiva e $\pi_j = \lim_{n \to +\infty} P_{ij}^n$.

Exercício 2.20. Considere uma C.M. sobre o espaço um espaço de estados $E = \{1, 2, 3, 4, 5, 6\}$ e com matriz de transição:

$$\mathbb{P} = \begin{bmatrix} 0.5 & 0.5 & 0 & 0 & 0 & 0 \\ 0.25 & 0.75 & 0 & 0 & 0 & 0 \\ 0.25 & 0.25 & 0.25 & 0.25 & 0 & 0 \\ 0.25 & 0 & 0.25 & 0.25 & 0 & 0.25 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 \end{bmatrix}.$$

(a) Classifique os estados da cadeia identificando as classes fechadas e a periodicidade de todos os estados da cadeia.

(b) Determine a parobabilidade de que a cadeia, partindo do estado 1, regresse novamente a 1, pela primeira vez, em n passos.

(c) Determine o número médio de transições necessárias para que a cadeia, partindo de 1 volte a 1, isto é, o tempo médio de recorrência do estado 1.

(d) Encontre a distribuição estacionária relativa à C.M. restrita ao sub-espaço $\{1, 2\} \subset E$. A partir desta, determine o tempo médio de recorrência para o estado 1.

Exercício 2.21. Relativamente ao funcionamento de uma máquina analisa-se a durabilidade, em número de dias completos, de um certo tipo de peça. Para tal, considere-se que sempre que a peça falha a máquina pára, procedendo-se à substituição da peça por outra idêntica, de modo que no dia seguinte a máquina retoma o seu funcionamento com a nova peça.

Seja Z_{n+1} o tempo de vida (contado em dias completos) da peça instalada no $n-$ésimo dia, e denote por p_k a probabilidade de que uma peça nova dure k dias completos, com $k = 0, 1, 2, ...$

Represente por X_n o tempo de vida (contado em dias completos) que resta à peça que está em uso no $n-$ésimo dia de observação do processo.

(a) Prove que o processo $(X_n : n \in \mathbb{N}_0)$ é uma C.M. homogénea sobre o espaço $\mathbb{N}_0$ e com matriz de transição:

$$\mathbb{P} = \begin{bmatrix} p_0 & p_1 & p_2 & ... \\ 1 & 0 & 0 & ... \\ 0 & 1 & 0 & ... \\ 0 & 0 & 1 & ... \\ ... & ... & ... & ... \end{bmatrix}.$$

(b) A cadeia $(X_n : n \in \mathbb{N}_0)$ é irredutível e aperiódica? Justifique.

(c) Defina distribuição estacionária de uma C.M. e mostre que a cadeia dada possui distribuição estacionária sse o tempo médio de vida das peças novas é finito, isto é,

$$\sum_{k=0}^{+\infty} k p_k < +\infty.$$

Note que $p_0 + p_1 + p_2 + \cdots = 1$.

(d) Sob que condição a cadeia dada é ergódica? Justifique.

Capítulo 3

Cadeias de Markov em tempo contínuo

Bibliografia

Principal

- Muller, D. (2007) Processos Estocásticos e Aplicações. II Série, nº3, Coleção Económicas. Almedina.

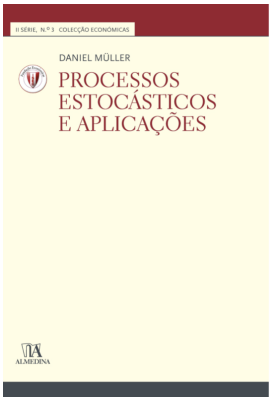

Secundária

- Muller, D. (2011) Probabilidades e Processos Estocásticos. II Série, nº17, Coleção Económicas. Almedina.

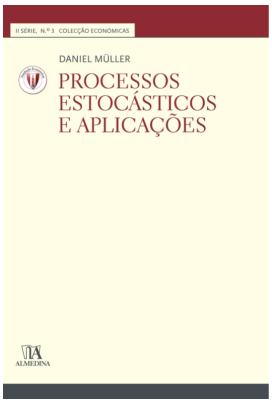

- Taylor, H. M., Karlin, S. (1998) An Introduction to Stochastic Modeling (3rd Edition), Academic Press, New York.

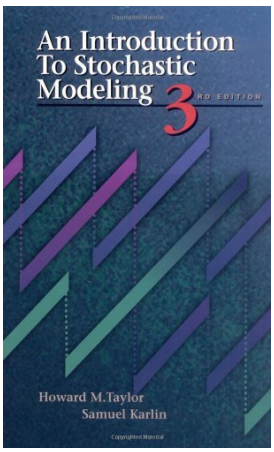

Todos os direitos reservados. Nenhuma parte do conteúdo deste sítio pode ser reproduzida ou distribuída sem a autorização prévia por escrito do autor. Sem autorização prévia por escrito, não é permitido copiar ou reproduzir o texto, código e imagens.

2025 | Nuno M. Brites | nbrites@iseg.ulisboa.pt